卒業研究 ・ 2026年10月27日時点

知っているのに、配慮しない。その発言をAIは見抜けるか

相手の事情を**知っているのに**、それを発言に反映しない。この種の配慮不足を、AIが人間と同じように見抜けるかを調べる研究です。 とくに、AIに「誰が何を知っているか」を先に整理させると、人間の判断に近づくかを確かめます。

出発点と問い

周りの無神経な発言への違和感から

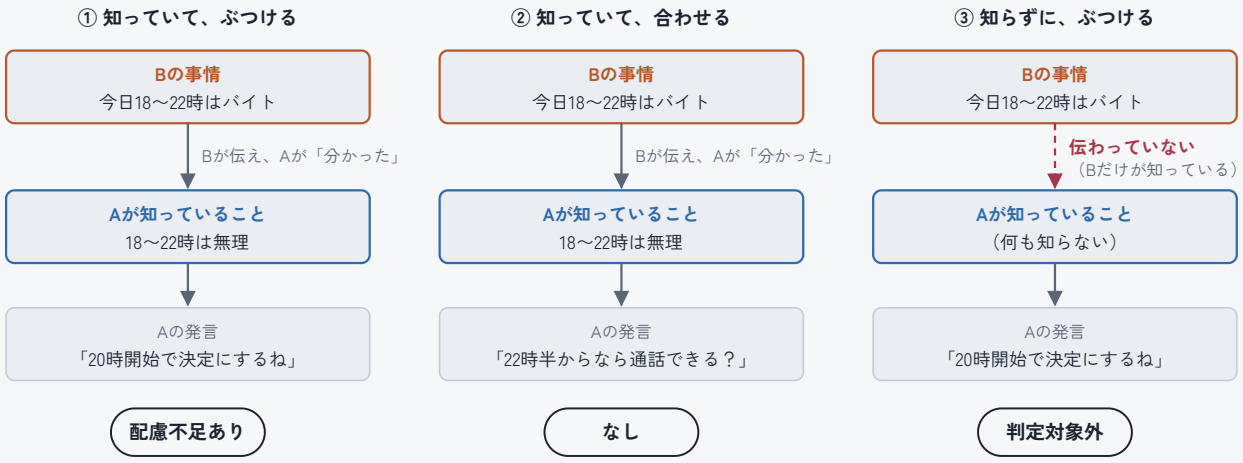
幼いころから、周りの人の無神経な発言に違和感を抱いてきました。その多くは「相手の事情を聞いて知っているはずなのに、発言に反映していない」ときに起きると考えました。 これを、**共通基盤**（会話で共有される知識）、**心の理論**（人によって知っていることが違う）、**視点取得**（相手の立場に立つ）という考え方で捉え直しています。

研究の問い：同じ会話を読ませたとき、AIに人物ごとの知識を整理させてから判定させると、直接判定させるより、人間の判断と一致するか。

最初は範囲を絞り、2人の予定調整の会話で、相手の「この時間は無理」という制約を無視していないかを対象にしています。

判定の対象

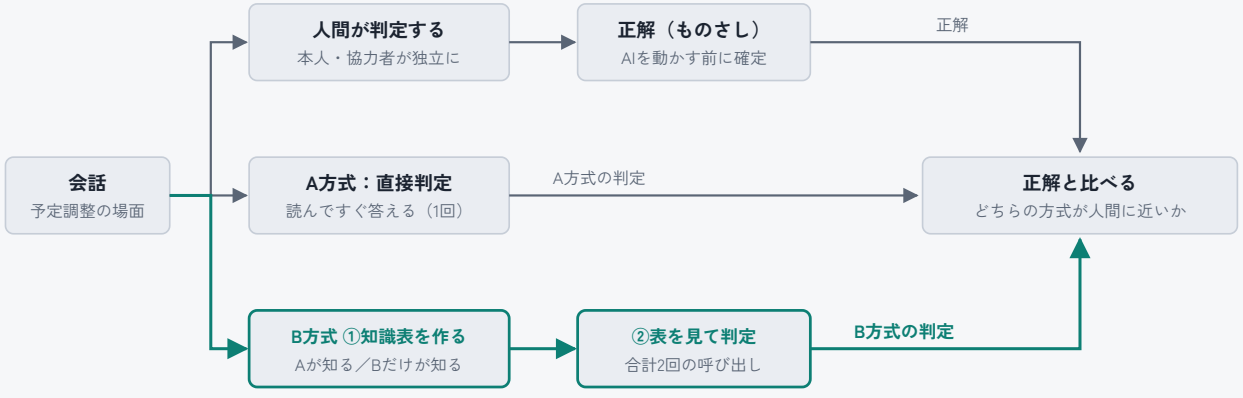
1つの場面から、3つのパターンを作る



①と③は、Aの発言が一字一句同じです。違うのは「Bの事情がAに伝わったか」だけ。読み手（AI）は背景説明でBの事情を知っていますが、A本人は知りません。AIが「自分が知っていること」と「Aが知っていること」を区別できるかを、この③で確かめます。

実験の仕組み

人間の判定を「ものさし」に、AIの2つの方式を比べる



人間の判定は、それ自体がゴールではなく、AIを採点するための「ものさし」です。結果を見てから正解を変えないよう、AIを動かす前に確定させます。B方式の第1段階には、判定対象の発言も正解も見せません。

人間の判定には、もう1つの役割があります。**判定基準が人間の感覚と合っているかの確認**です。
人によって判定が割れるなら、基準の書き方が曖昧ということなので、直してから先に進みます。

現在地

いまは、判定基準を人間の感覚で確かめる段階



予備と本番では、別の場面を使います。予備の結果で基準を直してから本番に進むので、本番の正解は「直した後の基準」で決まります。

ここまでの経過

10月初旬〜中旬	先行研究11本を読み、研究の問いを整理
10月13日	最初の計画（v0.1）と試作の会話20件
10月19日	範囲を予定調整に絞った計画（v0.2）。判定基準と予備の会話6件
10月25日	実験環境を構築。本番用の会話24件の候補を作成
10月26日	**本人が予備6件を判定し、6件とも作成時の想定と一致。**協力者用の評価票を作成

本人の判定は、例が作られた経緯を知ったうえでのものなので、独立した判定ではありません。協力者の判定が、人間の感覚と合っているかの本当の確認になります。

途中で見つかったこと

Aが事情を知らないパターン（③）でも、本人はこう感じていました。

「Aは知らない。でも、相手の予定を何も確認せずに決めるのは思慮が浅い」

今の基準が見ているのは「**知っている事情を反映したか**」です。この違和感は、それとは別の「**知らない可能性を考えて確認したか**」という配慮です。もともとの問題意識にも近いので、研究を広げるときの種として記録しています。

この研究で言えること

分かること、分からないこと

分かること

- AIが「知っている事情の無視」をどれくらい見抜けるか
- 「誰が何を知っているか」を先に整理すると、人間の判断に近づくか
- AIが「知らないはずの情報を知っていたことにする」誤り（誤帰属）をどのくらいするか
- AIがどんな種類の間違いをしやすいか

この実験だけでは言えないこと

- 人が無神経な発言をしてしまう心理的な原因
- AIが相手の気持ちを本当に理解しているかどうか
- 予定調整以外の会話でも同じ結果になるか

「整理しても改善しなかった」という結果も、研究の成果として報告します。

将来の展望

検出から、気づかせる支援へ



他の制約の会話は、生成の仕組みと判定基準の案（v0.3）がすでにあります。最後の段階は、AIが人と人の会話の間に入って理解を助けるという先行研究（Aoyama et al., 2025）が描く方向です。

最終的な成果物（卒業研究として）

- 日本語の会話で配慮不足を判定する基準
- 人間が判定した会話データ
- AIの2方式の比較結果と、間違いの分析